TALLER 1

DOCENTE:

FREDDY ALEXANDER ORJUELA

PRESENTADO ´POR:

EDUAR JHOVANNY AMAYA QUENGUAN
ISMAEL LARA GOMEZ
HERNY DONOSO

UNIVERSIDAD ECCI
SISTEMAS AVANZADOS DE PRODUCCION
FACULTAD DE INGENIERIA INDUSTRIAL
BOGOTÁ D.C.
2026

INTRODUCCION

Todos los días en las empresas en algún momento surge la duda si la publicidad realmente ayuda a aumentar las ventas y, sobre todo, qué medios funcionan mejor. El conjunto de datos Advertising nos ayudar a buscar la respuesta a esa pregunta porque contiene información sobre cuánto se invierte en este caso específico en televisión, radio y prensa, junto con las ventas alcanzadas .El objetivo de este primer taller es entender cómo se comportan estas variables y qué tan fuerte es la relación entre la inversión en televisión, radio y prensa y las ventas de la empresa. Para esto, primero se exploran los datos para conocer su distribución y detectar posibles patrones. Luego se aplican modelos de regresión para medir el impacto de cada medio publicitario y, finalmente, se compara este enfoque con un árbol de decisión, que permite descubrir relaciones no lineales entre las variables. Con los resultados de este primer taller buscamos no solo obtener resultados numéricos, sino también interpretar qué significan para la toma de decisiones y qué modelo ofrece una mejor forma de predecir las ventas.

FASE 1: Estadística Descriptiva y Análisis Exploratorio

2. Caracterización Numérica: Elabore una tabla que resuma las estadísticas descriptivas para las variables TV, Radio, Newspaper y Sales. Esta tabla debe reportar: Media y Mediana (Medidas de tendencia central). Desviación estándar, Mínimo y máximo (Medidas de dispersión). Sesgo (Skewness) y Curtosis (Medidas de forma).

Medidas de Tendencia Central y Dispersión

Variable	Media (Mean)	Mediana (Median)	Desv. Estándar (Std)	Mínimo (Min)	Máximo (Max)	Asimetría (Skewness)	Curtosis (Kurtosis)
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Variable	Media (Mean)	Mediana (Median)	Desv. Estándar (Std)	Mínimo (Min)	Máximo (Max)	Asimetría (Skewness)	Curtosis (Kurtosis)
Radio	23.2640	22.9	14.846809	0.0	49.6	0.094175	-1.260401
Sales	14.0225	12.9	5.217457	1.6	27.0	0.407571	-0.408869

Variable	Media (Mean)	Mediana (Median)	Desv. Estándar (Std)	Mínimo (Min)	Máximo (Max)	Asimetría (Skewness)	Curtosis (Kurtosis)
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

3. Análisis de Distribución y Atípicos: Construya un histograma y un diagrama de caja (Box Plot) para cada variable. Determine la simetría de las distribuciones.

TELEVISION

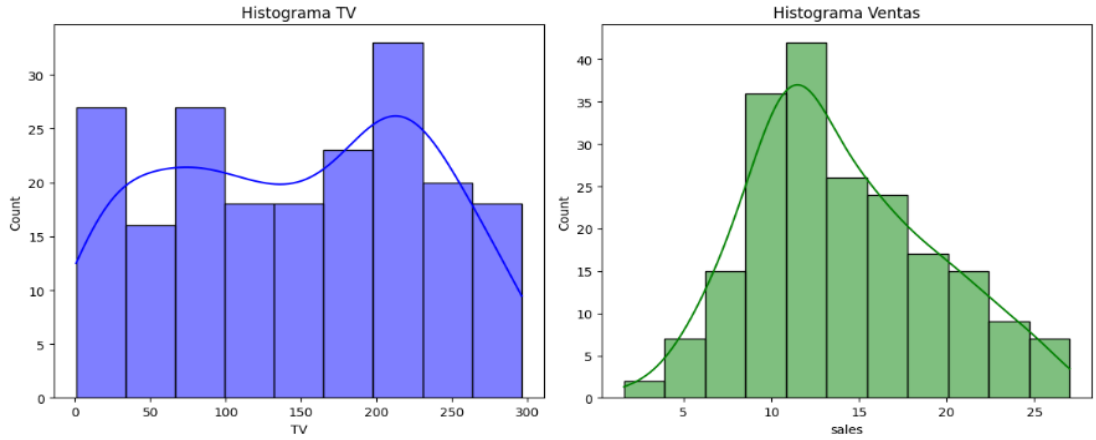

Figura1 **Histograma TV (Azul):** Observamos una distribución uniforme ya que su asimetría es negativa el cual es de -0.069853 . **Histograma Ventas (Verde):** Esta variable presenta una ligera asimetría hacia la derecha (sesgo positivo) en cual es de 0.407571.

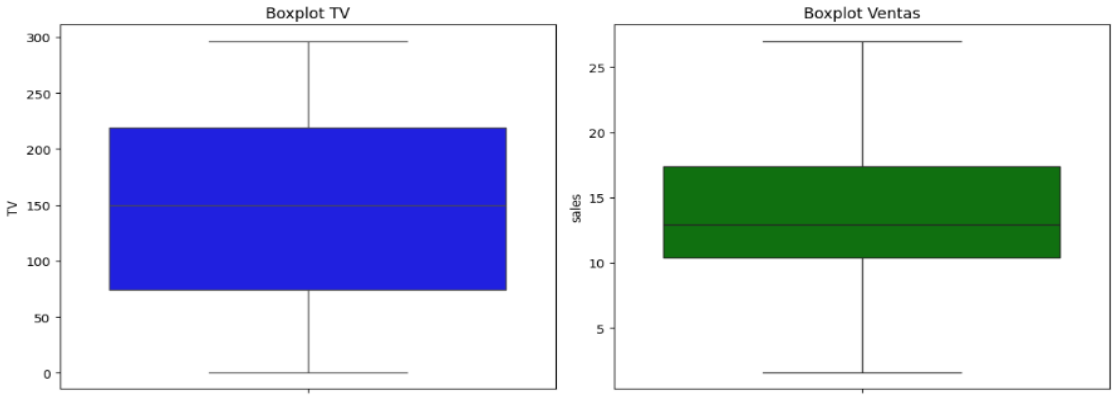

Figura2 **Boxplot TV (Azul):** la mediana está casi en el centro de la caja, lo que sugiere que no hay un sesgo extremo en los datos y sin presencia de outliers. **Boxplot Ventas (Verde):** El 50% de las ventas se concentra entre 10.5 y 17.5. La dispersión es moderada ya que tampoco hay presencia de outliers

RADIO

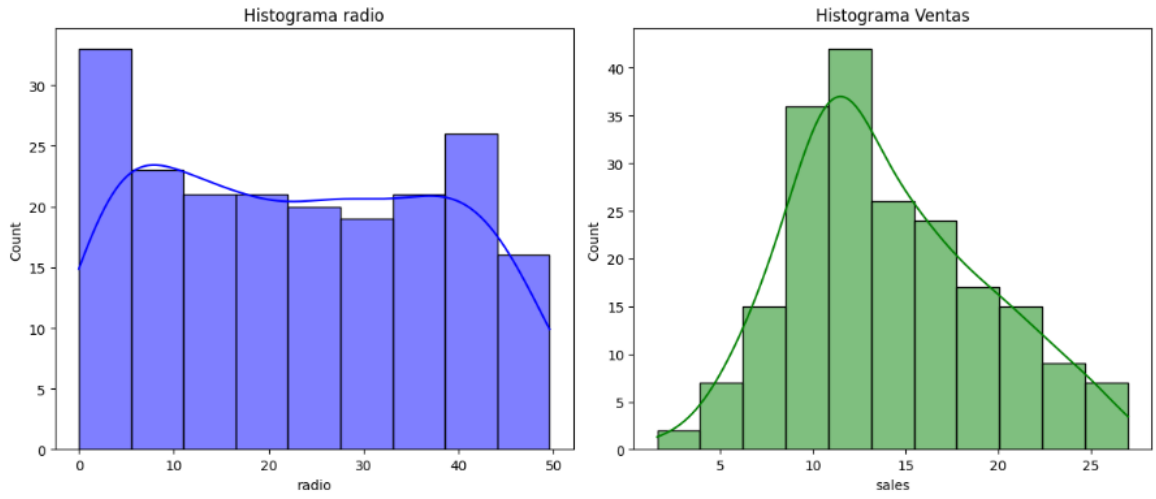

Figura3 **Histograma Radio (Azul):** Observamos una distribución uniforme ya que su asimetría es aproximadamente 0 el cual es de 0.094175. **Histograma Ventas (Verde):** Esta variable presenta una ligera asimetría hacia la derecha (sesgo positivo) en cual es de 0.407571.

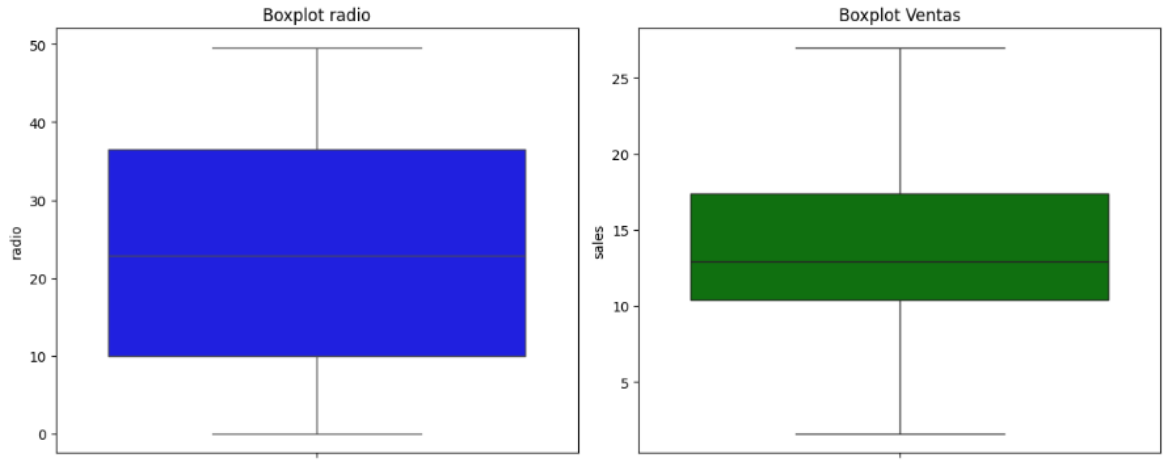

Figura4 **Boxplot Radio (Azul):** la mediana está casi en el centro de la caja, lo que sugiere que no hay un sesgo extremo en los datos y sin presencia de outliers. **Boxplot Ventas (Verde):** El 50% de las ventas se concentra entre 10.5 y 17.5. La dispersión es moderada ya que tampoco hay presencia de outliers

NEWSPAPER

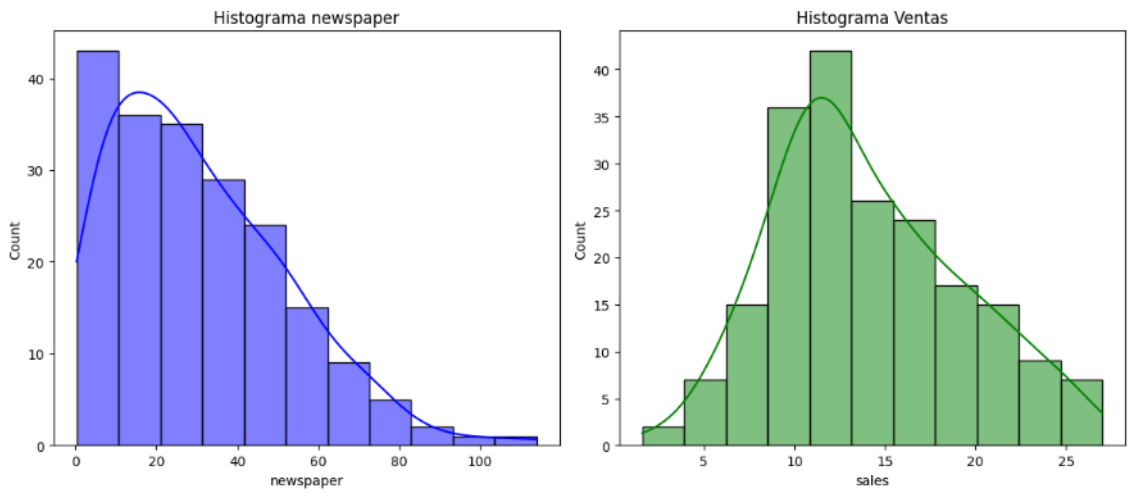

Figura5 **Histograma TV (Azul):** Observamos una asimetría hacia la derecha (sesgo positivo) el cual es de 0.894720. **Histograma Ventas (Verde):** Esta variable presenta una ligera asimetría hacia la derecha (sesgo positivo) en cual es de 0.407571.

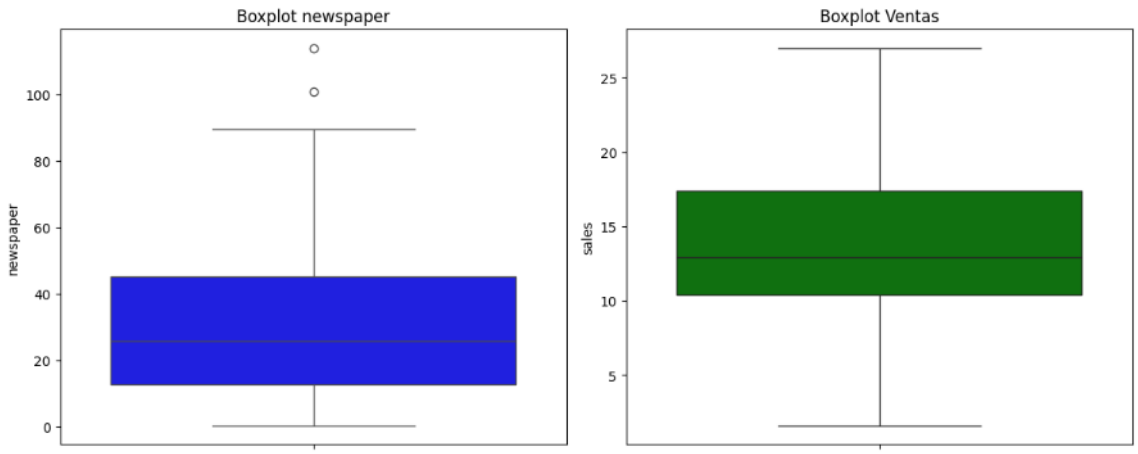

Figura6 **Boxplot Newspaper (Azul):** El 50% central de la inversión en periódico está entre 12 y 45. presenta mayor dispersión como se observa en su posición, además de eso se observan valores atípicos superiores a 90. **Boxplot Ventas (Verde):** El 50% de las ventas se concentra entre 10.5 y 17.5. La dispersión es moderada y no hay presencia de outliers

Determine la simetría de las distribuciones.

TV: Distribución Uniforme
Radio: Distribución Uniforme
Newpaper: Distribución con isometría a la derecha (sesgo positivo)
Ventas: Distribución con isometría a la derecha (sesgo positivo)

Responda: ¿Se identifican datos atípicos u observaciones que se alejan significativamente de la masa de los datos? Explique cómo podrían influir estas observaciones en la trayectoria de una línea de regreso.

Se observa en el histograma de Newspaper una mayor dispersión, así como la presencia de outliers por encima del rango lo que indica que los datos no son totalmente precisos o confiables que podrían afectar la estabilidad del modelo y predictibilidad.

4. Exploración de la Nube de Puntos: Genere los dispersos gramas (Scatter Plots) de la variable respuesta (Sales) frente a cada covariable.

TELEVISON

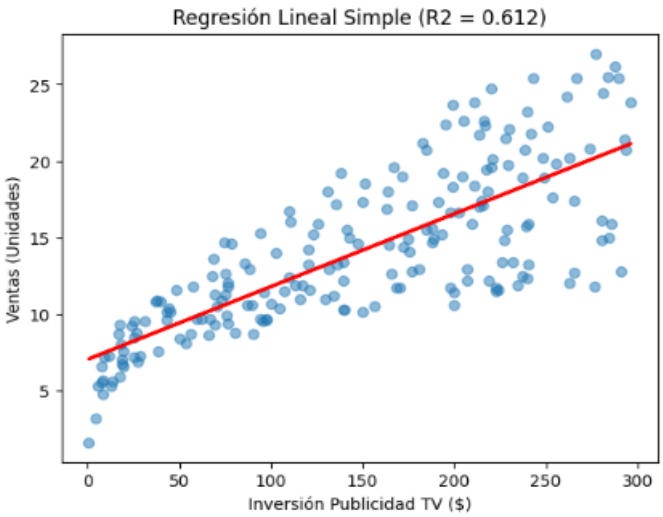

Figura7 El dispersograma ventas vs TV muestra una relación lineal positiva y definida. Donde la mayoría de los puntos siguen la tendencia de la recta de regresión, No se observan patrones diferente o complejos. Con un R2= 0.612

RADIO

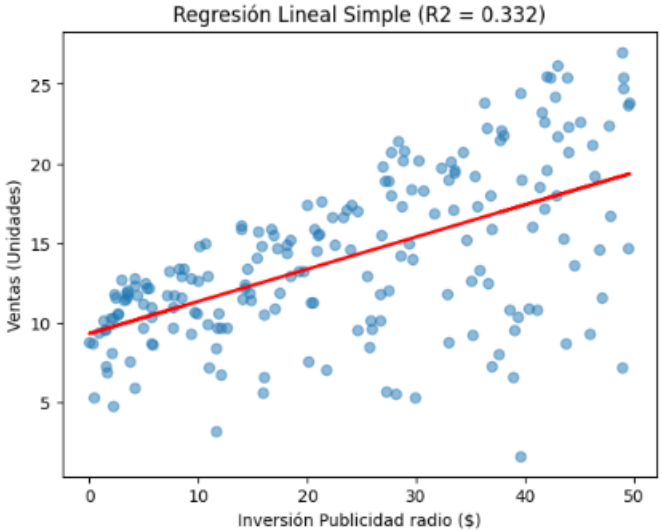

Figura8 La gráfica de ventas vs inversión en radio presenta una relación lineal positiva moderada ya que los puntos están más dispersos alrededor de la recta en comparación con TV. No se identifican parábolas o patrones complejos, aunque su R2= 0.32 es mucho menor explicativo

NEWSPAPER

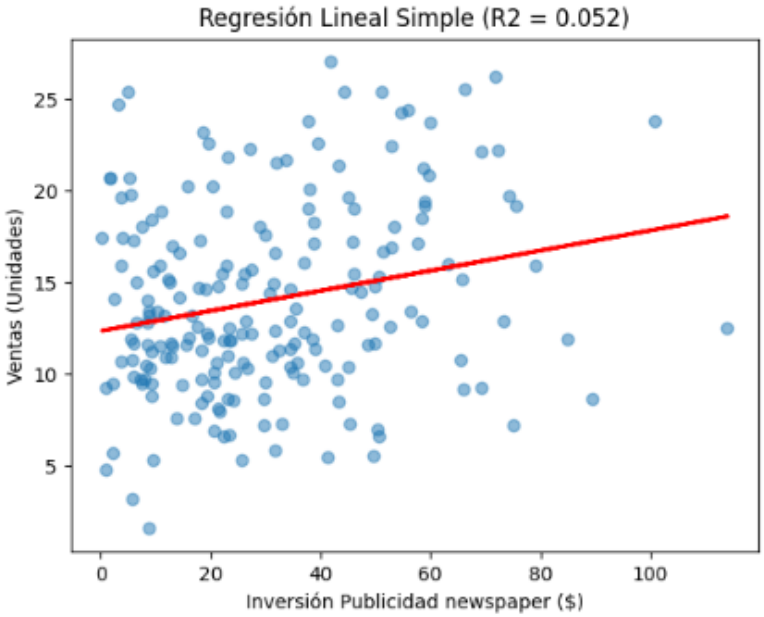

Figura9 El dispersograma entre ventas vs inversión en newspaper se observa una nube de puntos bastante dispersa lo que indica una tendencia lineal muy débil. La

recta de regresión tiene una pendiente positiva leve, pero la variabilidad es alta y la relación no es claramente definida. No se observan parábolas o patrones complejos y su capacidad explicativa es muy baja de R2= 0.052

5. Evaluación de Asociación: Calcule y presente las matrices de correlación de Pearson y Spearman. El coeficiente de Pearson evaluara la fuerza de la asociación lineal. El coeficiente de Sp

TELEVISION

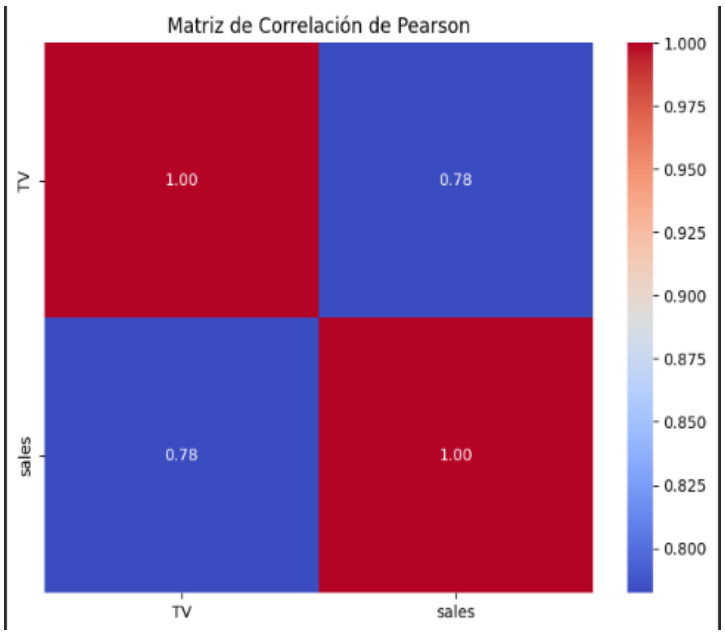

Figura10: en esta figura se observa la matriz de correlación de Pearson para variable dependiente sales y la variable independiente publicidad invertida en TV.

TV vs TV de acuerdo a valor de 1.00 obtenido en la correlación de Pearson encontramos que esta variable tiene una correlación perfecta y positiva

Ventas vs TV de acuerdo a valor de 0.78 obtenido en la correlación de Pearson encontramos que las variables tv y sales tiene una correlación alta y positiva

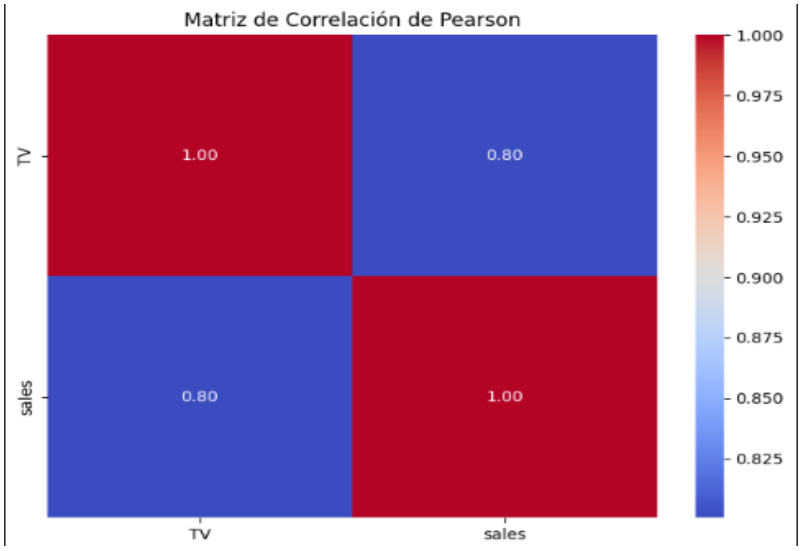

Figura11: en esta figura se observa la matriz de correlación de Spearman para variable dependiente sales y la variable independiente publicidad invertida en TV.

TV vs TV de acuerdo a valor de 1.00 obtenido en la correlación de Spearman encontramos que esta variable tiene una correlación monotónica

Ventas vs TV de acuerdo a valor de 0.78 obtenido en la correlación de Spearman encontramos que las variables tv y sales tiene una correlación fuerte

RADIO

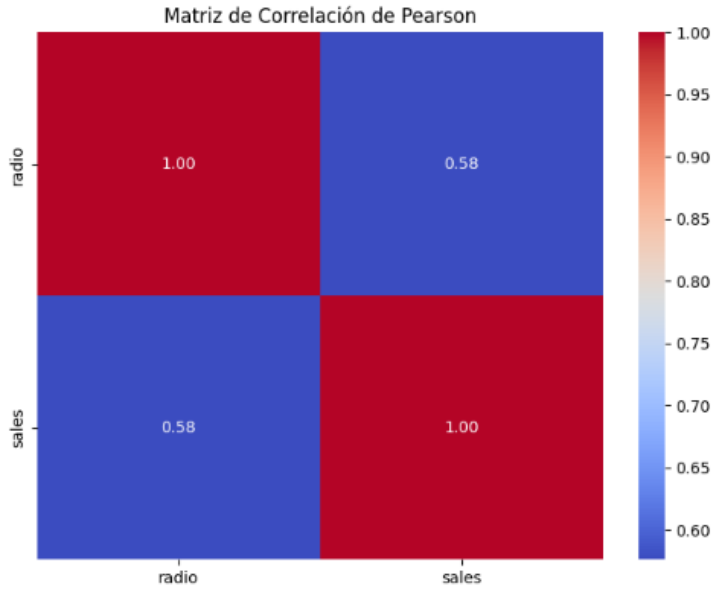

Figura12: en esta figura se observa la matriz de correlación de Pearson para variable dependiente sales y la variable independiente publicidad invertida en Radio.

Radio vs Radio de acuerdo a valor de 1.00 obtenido en la correlación de Pearson encontramos que esta variable tiene una correlación perfecta y positiva

Ventas vs Radio de acuerdo a valor de 0.58 obtenido en la correlación de Pearson encontramos que las variables radio y sales tiene una correlación moderada y positiva

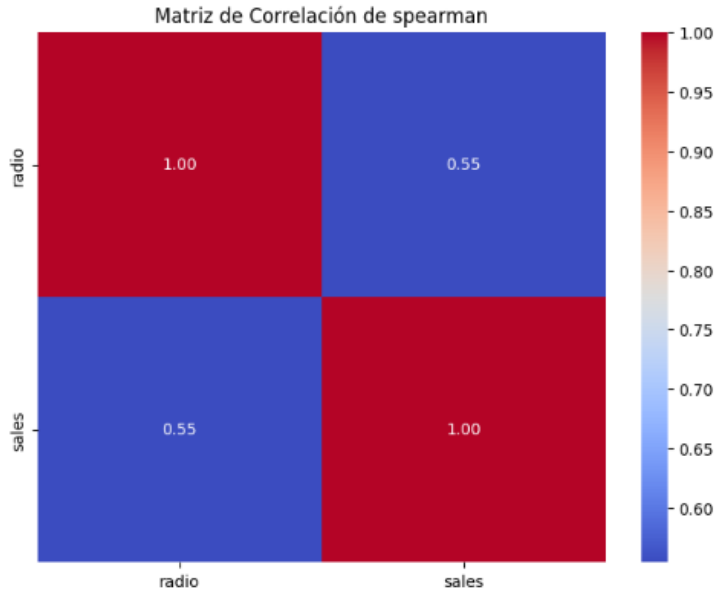

Figura13: en esta figura se observa la matriz de correlación de Spearman para variable dependiente sales y la variable independiente publicidad invertida en Radio.

Radio vs Radio de acuerdo a valor de 1.00 obtenido en la correlación de Spearman encontramos que esta variable tiene una correlación monotónica

Ventas vs Radio de acuerdo a valor de 0.58 obtenido en la correlación de Spearman encontramos que las variables radio y sales tiene una correlación moderada

NEWSPAPER

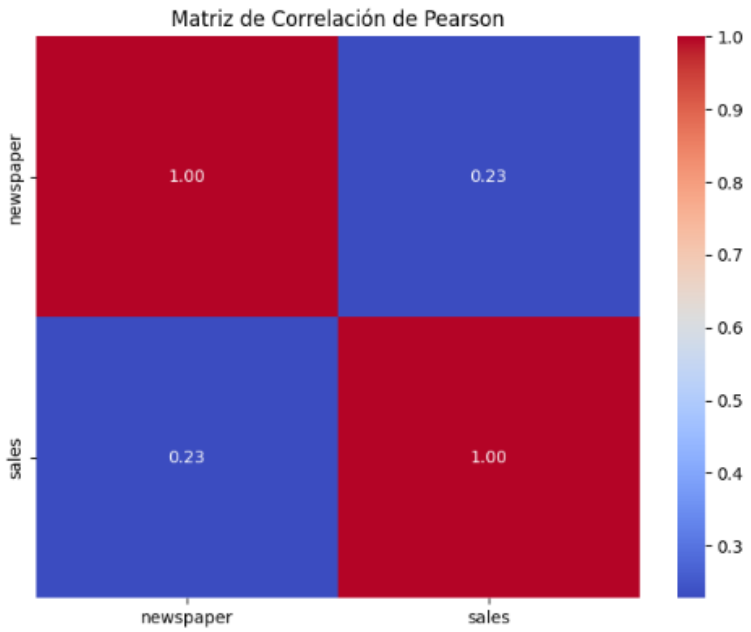

Figura14: en esta figura se observa la matriz de correlación de Pearson para variable dependiente sales y la variable independiente publicidad invertida en Newspaper.

Newspaper vs Newspaper: de acuerdo a valor de 1.00 obtenido en la correlación de Pearson encontramos que esta variable tiene una correlación perfecta y positiva

Ventas vs Newspaper: de acuerdo a valor de 0.23 obtenido en la correlación de Pearson
encontramos que las variables Newspaper y sales tiene una correlación baja y positiva

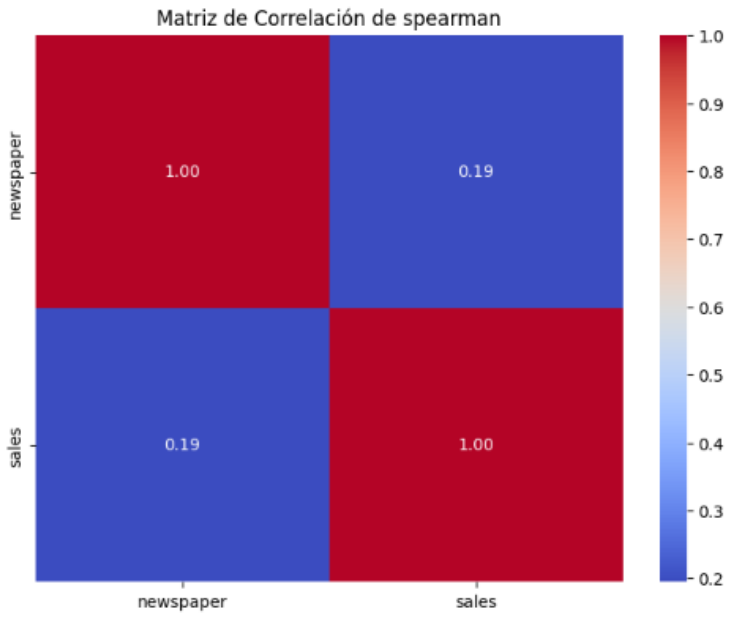

Figura15: en esta figura se observa la matriz de correlación de Spearman para variable dependiente sales y la variable independiente publicidad invertida en Newspaper.

Newspaper vs Newspaper: de acuerdo a valor de 1.00 obtenido en la correlación de Spearman encontramos que esta variable tiene una correlación monotónica

Ventas vs Newspaper: de acuerdo a valor de 0.23 obtenido en la correlación de Spearman encontramos que las variables Newspaper y sales tiene una correlación débil

6. Interpretación de Resultados: A partir de las métricas obtenidas en el punto anterior, responda:

¿Qué significa un coeficiente cercano a 1 o −1 en el contexto de la inversión publicitaria y el retorno en ventas?

Un coeficiente de correlación cercano a **1** nos indica una relación positiva fuerte entre la inversión publicitaria y las ventas, es decir, que cuando aumenta la inversión

en un medio por ejemplo, TV con r ≈ 0.78, las ventas tienden a aumentar de manera proporcional y consistente por otro lado si, este está cercano a **−1** nos indica una relación negativa, es decir que, al aumentar la inversión, las ventas no aumentaran proporcionalmente sino que disminuirían, situación que no se presenta en este estudio aunque newpapers tenga un r≈ 0.19.

¿Como se interpreta un valor de correlación cercano a 0? Compare ambos coeficientes (Pearson y Spearman).

Medio	**Pearson**	**Spearman**
TV	0.78	0.80
Radio	0.58	0.55
Newspaper	0.23	0.19

Tabla 1. Comparación Pearson y Spearman

Un valor de correlación cercano a **0** indica que no existe una relación lineal fuerte entre las variables. En el caso de *Newspaper* (r ≈ 0.23), la relación con ventas es débil, lo que significa que invertir más en prensa no garantiza un aumento significativo en las ventas.
El coeficiente de Pearson mide la relación lineal, mientras que Spearman mide la relación monotónica (basada en rangos). En los resultados obtenidos, ambos coeficientes son muy similares, lo que indica que la relación no solo es monotónica sino también lineal.

¿Sugieren estos resultados que las relaciones son estrictamente lineales? Justifique su respuesta basándose en la forma de la nube de puntos observada.

Los resultados muestran que las relaciones de TV y Radio, son lineales, ya que las nubes de puntos muestran una tendencia creciente sin patrones curvos evidentes y los coeficientes de Pearson y Spearman son similares. Sin embargo, no se puede afirmar que sean estrictamente lineales en términos absolutos, ya que existe dispersión en los datos (especialmente en Radio y Newspaper). Sobre todo, para *Newspaper* ya que la nube de puntos es bastante dispersa, lo que indica una

relación débil, no hay un patrón claramente definido, por lo tanto, no podría ser lineal.

FASE 2: REGRESIÓN LINEAL Y DIAGNÓSTICO

1. **Modelamiento Múltiple:** Estime un modelo de regresión lineal múltiple donde las ventas (Sales) dependan de la inversión en TV, Radio y Newspaper. Reporte los valores numéricos del intercepto (βˆ 0) y los coeficientes de pendiente (βˆ 1, βˆ 2, βˆ 3)).

```
# 5. Modelo de Regresión
X = df[['TV', 'radio', 'newspaper']]
y = df['sales']
model = LinearRegression().fit(X, y)
y_pred = model.predict(X)

# Imprimir los coeficientes del modelo
print(f"Intercepto (beta_0): {model.intercept_:.4f}")
print(f"Pendiente (beta_1): {model.coef_[0]:.4f}")
print(f"Pendiente (beta_1): {model.coef_[1]:.4f}")
print(f"Pendiente (beta_1): {model.coef_[2]:.4f}")

Intercepto (beta_0): 2.9389
Pendiente (beta_1): 0.0458
Pendiente (beta_1): 0.1885
Pendiente (beta_1): -0.0010
```

Figura16: Código Colab calculo interceptos

$$\boldsymbol{Ventas = 2.9389 + 0.0458(TV) + 0.1885(Radio) - 0.0010(Newspaper)}$$

2. **Interpretación de Parámetros**: Explique con sus propias palabras el significado de los resultados obtenidos:

   - Interprete el intercepto βˆ 0 indicando si tiene sentido conceptual que sea diferente de cero

   - Interprete los coeficientes βˆ 1, βˆ 2 y βˆ 3 bajo el concepto de variación de la media de Y cuando hay un incremento unitario de la covariable, manteniendo la otra constante (ceteris paribus).

Interpretación

Intercepto ventas (β_0 = 2.9389) Si la inversión en TV, Radio y Newspaper fuera 0, las ventas esperadas serían aproximadamente 2.94 unidades. Se puede interpretar como el nivel de de ventas base

Intercepto TV (β_1 = 0.0458) Por cada unidad adicional invertida en TV, las ventas aumentan en promedio 0.0458 unidades, manteniendo constantes Radio y Newspaper.
Es una relación positiva, por lo tanto, Más inversión en TV, se tiene más ventas.

Intercepto Radio (β_2 = 0.1885) Por cada unidad adicional invertida en radio, las ventas aumentan en promedio 0.1885 unidades, manteniendo constantes las demás variables. Es el coeficiente más alto. Esto indica que radio tiene mayor impacto marginal en ventas que TV.

Intercepto Newspaper (β_3 = −0.0010) nos indica que, por cada unidad adicional invertida en prensa, las ventas disminuyen en promedio 0.0010 unidades, manteniendo constantes las demás variables. Es un efecto muy pequeño y negativo.

3. **Análisis de Bondad de Ajuste:** Calcule el coeficiente de determinación R2 . Indique que proporción de la variabilidad total de las ventas es explicada por el modelo y analice si la inclusión de la variable Radio y Newspaper mejoro significativamente el ajuste respecto al modelo simple de la Fase 1.

```python
# Supongamos que df ya contiene los datos cargados de Advertising.csv
X = df[['TV', 'radio', 'newspaper']]
y = df['sales']

# Ajustar el modelo de Regresión Múltiple
model_multiple = LinearRegression()
model_multiple.fit(X, y)

# 3. Obtener e imprimir resultados
intercepto = model_multiple.intercept_
coeficientes = model_multiple.coef_
r_cuadrado = model_multiple.score(X, y)

print(f"--- Coeficientes del Modelo ---")
print(f"Intercepto (beta_0): {intercepto:.4f}")
print(f"Coeficiente TV (beta_1): {coeficientes[0]:.4f}")
print(f"Coeficiente Radio (beta_2): {coeficientes[1]:.4f}")
print(f"Coeficiente Newspaper (beta_3): {coeficientes[2]:.4f}")
print(f"\n--- Bondad de Ajuste ---")
print(f"R-cuadrado (R2): {r_cuadrado:.4f}")
```

```
--- Coeficientes del Modelo ---
Intercepto (beta_0): 2.9389
Coeficiente TV (beta_1): 0.0458
Coeficiente Radio (beta_2): 0.1885
Coeficiente Newspaper (beta_3): -0.0010

--- Bondad de Ajuste ---
R-cuadrado (R2): 0.8972
```

Figura17:Coeficiente de determinación Google Colab

Este valor es excelente ya que indica la combinación de TV, radio y newspaper que no ayuda a entender casi el 90 % de la varianza que se van tener en las ventas.

En cuanto a la comparación al añadir radio y newpaper Obtenemos un modelo capaza de explicar un 28.5 % más de la realidad que el modelo el modelo que usa solo TV.

4. **Estimación Matricial**: Considere el siguiente conjunto de 5 observaciones para una regresión lineal simple. Utilizando la formulación matricial $\hat{\beta} = (X'X)^{-1}X'Y$, encuentre los estimadores $\hat{\beta}_0$ (intercepto) y $\hat{\beta}_1$ (pendiente). Dadas las matrices de diseño X y el vector de respuesta Y :

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Tarea:

Calcule la matriz transpuesta X′

$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

Calcule el producto X′X y su respectiva matriz inversa $(X'X)^{-1}$.

$$X'X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

Calcule el producto X′Y.

$$(X'X)^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

$$(X'X)^{-1} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}$$

Obtenga el vector de parámetros $\hat{\beta}$ y escriba la ecuación de la recta estimada $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.

$$X'Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix} = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

$$\hat{\beta} = (X'X)^{-1}X'Y$$

$$\hat{\beta} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix} \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

Multiplicamos:

$$\hat{\beta}_0 = 1.1(28) - 0.3(101) = 30.8 - 30.3 = 0.5$$

$$\hat{\beta}_1 = -0.3(28) + 0.1(101) = -8.4 + 10.1 = 1.7$$

$$\boxed{\hat{\beta}_0 = 0.5}$$

$$\boxed{\hat{\beta}_1 = 1.7}$$

Ecuación recta estimada

$$\hat{y} = 0.5 + 1.7x$$

Fase 3: Arboles de Decisión y Comparación de Modelos

1. **Entrenamiento del Modelo**: Utilizando las variables TV y Radio, entrene un arbol de regresión para predecir las ventas (Sales). Grafique la estructura del arbol y explique bajo que criterio se realizan las particiones en los nodos

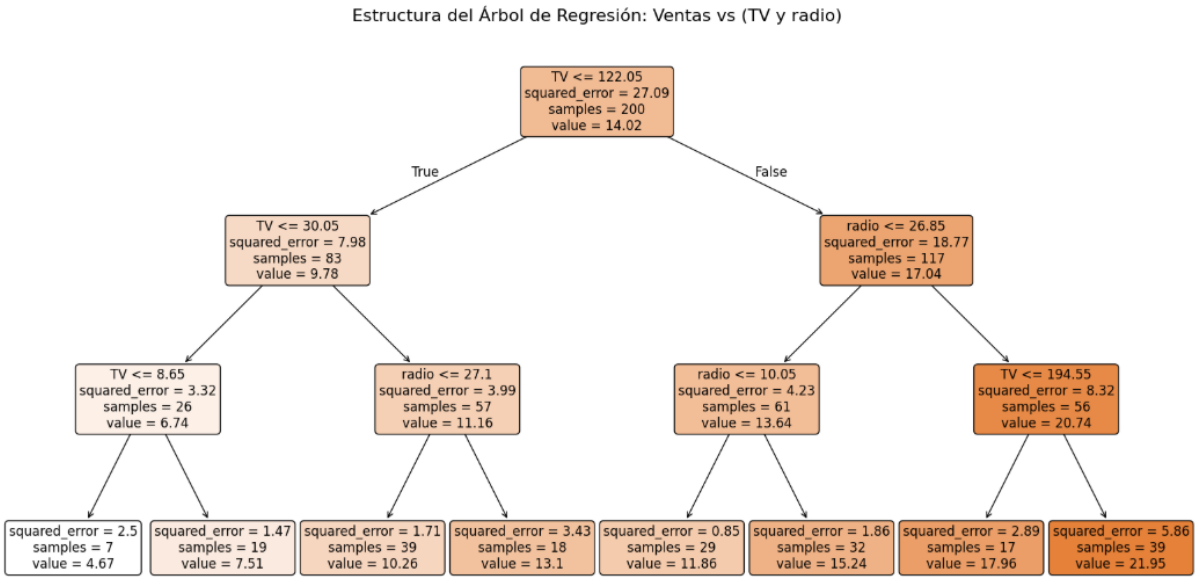

Figura18: Arbol decisión Google Colab

2. **Cálculo Manual de Incertidumbre (Clasificación)**: Suponga una versión simplificada del problema donde las ventas se categorizan en “Altas” y “Bajas” Con los siguientes datos de 4 mercados, calcule la reducción de la incertidumbre:

Mercado	Inversión TV	Ventas (Clase)
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas
4	Baja	Altas

Tareas:

Calcule la Entropía del Nodo Padre: H(S) = − Ppi log2 (pi).

Altas:3

Bajas:1

$$p(\text{Alta}) = \frac{3}{4}, \quad p(\text{Baja}) = \frac{1}{4}$$

$$H(S) = -\left(\frac{3}{4}\log_2\frac{3}{4} + \frac{1}{4}\log_2\frac{1}{4}\right)$$

$$H(S) = -\left(0.75(-0.415) + 0.25(-2)\right)$$

$$H(S) = 0.811 \text{ bits}$$

Calcule el Índice de Gini para el nodo padre: Gini = 1 − Pp 2 i .

$$G = 1 - (p_1^2 + p_2^2)$$

$$G = 1 - \left(\left(\frac{3}{4}\right)^2 + \left(\frac{1}{4}\right)^2\right)$$

$$G = 1 - (0.5625 + 0.0625) = 0.375$$

Determine la Ganancia de Información tras realizar una participación por la variable Inversión TV

División

TV = Alta: (Mercados 1 y 2)

Altas: 2

Bajas:0

TV = Baja: (Mercados 3 y 4)

Altas: 1

Bajas: 1

$$H = -\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right) = 1$$

$$H_{\text{después}} = \frac{2}{4}(0) + \frac{2}{4}(1) = 0.5$$

$$GI = H_{\text{padre}} - H_{\text{después}}$$

$$GI = 0.811 - 0.5 = 0.311$$

3. **Importancia de Predictores**: Identifique que variable tiene mayor peso en el arbol de decisión y compárela con los coeficientes obtenidos en la regresión múltiple de la Fase 2.

```
from sklearn.linear_model import LinearRegression

# 1. Obtener Importancias del Árbol
importances = tree_reg.feature_importances_

# 2. Entrenar Regresión Lineal para comparar
lr_model = LinearRegression().fit(X, y)

print("--- RESULTADOS COMPARATIVOS ---")
print(f"Importancia en el Árbol (TV):        {importances[0]:.4f}")
print(f"Importancia en el Árbol (radio): {importances[1]:.4f}")
print("-" * 35)
print(f"Coeficiente Regresión (TV):         {lr_model.coef_[0]:.4f}")
print(f"Coeficiente Regresión (radio):  {lr_model.coef_[1]:.4f}")

--- RESULTADOS COMPARATIVOS ---
Importancia en el Árbol (TV):        0.6425
Importancia en el Árbol (radio): 0.3575
-----------------------------------
Coeficiente Regresión (TV):         0.0458
Coeficiente Regresión (radio):  0.1880
```

Figura19: Google Colab calculo importancia arbol de decisión y coeficiente regresión lineal.

Medio	**Coeficiente fase 2**	**Coeficiente fase 3**	**Importancia arbol**
TV	0.0458	0.0458	0.6425
Radio	0.1885	0.1880	0.3475

Se observa que la variación entre el coeficiente calculados tanto en la fase 2 como fase 3 no varían casi nada y que dentro del arbol la TV es quien tiene la mayor importancia.

4. **Diagnóstico Comparativo**: Discuta en que escenarios sería preferible utilizar un modelo de regresión lineal frente a un arbol de decisión, considerando la interpretabilidad y la precisión del pronostico

    - Para utilizar el escenario de regresión lineal debemos tener clara la relación entre interacciones no lineales estables, en cambio para utilizar un arbol de decisión es necesario comprender que es un escenario visual fácil de explicar para cuando la relación presenta fuertes variaciones. Adicionalmente el árbol sirve permite visualizar los grupos de comportamiento como el responsable, pero no supera la precisión de la regresión lineal.

Conclusión

Para la regresión lineal múltiple resulta más robusta y precisa para predecir Sales, pues explica cerca del 90% de la variabilidad. Los árboles de decisión permiten visualizar reglas claras y segmentar los mercados, pero no capturan tan bien la relación lineal fuerte entre TV, Radio y las ventas. TV es el predictor más importante tanto en regresión como en el árbol, seguido de Radio, mientras que Newspaper aporta muy poca información.